

Distribució	PMF/PDF/CDF	Esperança	Variança
Bernoulli(<i>p</i>) <div><i>p</i> ∈ (0, 1)</div>	<div><i>P</i>(<i>X</i> = 1) = <i>p</i></div> <div><i>P</i>(<i>X</i> = 0) = <i>q</i> = 1 − <i>p</i></div>	<i>p</i>	<i>pq</i>
B(<i>n</i> , <i>p</i>) <div><i>n</i> ∈ ℕ, <i>p</i> ∈ (0, 1)</div>	<i>P</i> (<i>X</i> = <i>k</i>) = (n k) p k q n −<!-- − --> k {\displaystyle {\tbinom {n}{k}}p^{k}q^{n-k}} 	<i>np</i>	<i>npq</i>
Geom(<i>p</i>) <div><i>p</i> ∈ (0, 1)</div>	<i>P</i> (<i>X</i> = <i>k</i>) = <i>q</i> ^{<i>k</i>} <i>p</i>	 q p {\displaystyle {\frac {q}{p}}} 	 q p 2 {\displaystyle {\frac {q}{p^{2}}}}
Poiss(<i>λ</i>) <div><i>λ</i> ∈ (0, +∞)</div>	<i>P</i> (<i>X</i> = <i>k</i>) = e −<!-- − --> λ<!-- λ --> λ<!-- λ --> k k ! {\displaystyle {\frac {e^{-\lambda }\lambda ^{k}}{k!}}} 	<i>λ</i>	<i>λ</i>
U(<i>a</i> , <i>b</i>) <div>−∞ < <i>a</i> < <i>b</i> < +∞</div>	<div><i>f</i>(<i>x</i>) = 1 b −<!-- − --> a ⋅<!-- ⋅ --> 1 (a , b) (x) {\displaystyle {\frac {1}{b-a}}\cdot {\frac {1}{(a,b)}(x)}} </div> <div><i>F</i>(<i>x</i>) = x −<!-- − --> a b −<!-- − --> a ⋅<!-- ⋅ --> 1 (a , b) (x) {\displaystyle {\frac {x-a}{b-a}}\cdot {\frac {1}{(a,b)}(x)}} </div>	<div><i>m</i>₁ = a + b 2 {\displaystyle {\frac {a+b}{2}}} </div> <div><i>m</i>_{<i>n</i>} = ∑<!-- ∑ --> i = 0 n a i b n −<!-- − --> i n + 1 {\displaystyle {\frac {\sum _{i=0}^{n}a^{i}b^{n-i}}{n+1}}} </div>	 (b −<!-- − --> a) 2 12 {\displaystyle {\frac {(b-a)^{2}}{12}}}
<i>N</i> (<i>μ</i> , <i>σ</i> ²) <div><i>μ</i> ∈ ℝ, <i>σ</i> ∈ (0, +∞)</div>	<i>f</i> (<i>x</i>) = 1 σ<!-- σ --> √<!-- √ --> 2 π<!-- π --> e −<!-- − --> (x −<!-- − --> μ<!-- μ -->) 2 (2 σ<!-- σ --> 2) {\displaystyle {\frac {1}{\sigma {\sqrt {2\pi }}}}\,e^{-{\frac {(x-\mu)^{2}}{(2\sigma ^{2})}}}} 	<div><i>m</i>₁ = <i>μ</i></div> <div><i>m</i>₂ = <i>μ</i>² + <i>σ</i>²</div>	<i>σ</i> ²
Exp(<i>λ</i>) <div><i>λ</i> ∈ (0, +∞)</div>	<div><i>f</i>(<i>x</i>) = <i>λ</i><i>e</i>^{−<i>λx</i>} · 1 (0 , + ∞) (x) {\displaystyle {\frac {1}{(0,+\infty)}}(x)} </div> <div><i>F</i>(<i>x</i>) = (1 − <i>e</i>^{−<i>λx</i>}) · 1 (0 , + ∞) (x) {\displaystyle {\frac {1}{(0,+\infty)}}(x)} </div>	<div><i>m</i>₁ = 1 λ<!-- λ --> {\displaystyle {\frac {1}{\lambda }}} </div> <div><i>m</i>_{<i>n</i>} = n ! λ<!-- λ --> n {\displaystyle {\frac {n!}{\lambda ^{n}}}} </div>	 1 λ<!-- λ --> 2 {\displaystyle {\frac {1}{\lambda ^{2}}}}
Gamma(<i>α</i> , <i>β</i>) <div><i>α</i>, <i>β</i> ∈ (0, +∞)</div>	<i>f</i> (<i>x</i>) = α<!-- α --> β<!-- β --> Γ<!-- Γ --> (β<!-- β -->) ⋅<!-- ⋅ --> x β<!-- β --> −<!-- − --> 1 ⋅<!-- ⋅ --> e −<!-- − --> α<!-- α --> x ⋅<!-- ⋅ --> 1 (0 , + ∞) (x) {\displaystyle {\frac {\alpha ^{\beta }}{\Gamma (\beta)}}\cdot x^{\beta -1}\cdot e^{-\alpha x}\cdot {\frac {1}{(0,+\infty)}}(x)} 	 β<!-- β --> α<!-- α --> {\displaystyle {\frac {\beta }{\alpha }}} 	 β<!-- β --> α<!-- α --> 2 {\displaystyle {\frac {\beta }{\alpha ^{2}}}}
<i>LN</i> (<i>μ</i> , <i>σ</i> ²) <div><i>μ</i> ∈ ℝ, <i>σ</i> ∈ (0, +∞)</div>	<i>f</i> (<i>x</i>) = 1 x σ<!-- σ --> √<!-- √ --> 2 π<!-- π --> e −<!-- − --> (log ⁡<!-- ⁡ --> x −<!-- − --> μ<!-- μ -->) 2 2 σ<!-- σ --> 2 {\displaystyle {\frac {1}{x\sigma {\sqrt {2\pi }}}}\,e^{-{\frac {(\log x-\mu)^{2}}{2\sigma ^{2}}}}} 	<i>θ</i> = <i>e</i> ^{<i>μ</i> + σ<!-- σ --> 2 2 {\displaystyle {\frac {\sigma ^{2}}{2}}} }	<i>θ</i> ² (<i>e</i> ^{<i>σ</i>²} − 1)
<i>χ</i> _{<i>n</i>} ² <div><i>n</i> ∈ ℕ</div>	<i>f</i> (<i>x</i>) = 1 2 n 2 Γ<!-- Γ --> (n 2) x n 2 −<!-- − --> 1 e −<!-- − --> x 2 ⋅<!-- ⋅ --> 1 (0 , + ∞) (x) {\displaystyle {\frac {1}{2^{\frac {n}{2}}\Gamma ({\frac {n}{2}})}}x^{\frac {n}{2}-1}e^{-{\frac {x}{2}}}\cdot {\frac {1}{(0,+\infty)}}(x)} 	<i>n</i>	<i>2n</i>
<i>t</i> _{<i>n</i>} <div><i>n</i> ∈ ℕ (g. llibertat)</div>	<i>f</i> (<i>x</i>) = Γ<!-- Γ --> (n + 1 2) (1 + x 2 n) −<!-- − --> n + 1 2 {\displaystyle {\frac {\Gamma ({\frac {n+1}{2}})}{{\sqrt {n\pi }}\Gamma ({\frac {n}{2}})}}(1+{\frac {x^{2}}{n}})^{-{\frac {n+1}{2}}}} 	0 if <i>n</i> > 1	 n n −<!-- − --> 2 {\displaystyle {\frac {n}{n-2}}} if <i>n</i> > 2

1 (Exponencial-Gamma). Exp(*α*) ∼ Gamma(*α*, 1). (*Y*_{*i*})_{*i*} VAIID, *Y*_{*i*} ∼ Exp(*α*), aleshores ∑_{*i*} *Y*_{*i*} = *Z* ∼ Gamma(*α*, *n*). Γ(*p*) = ∫₀[∞] *x*^{*p*−1}*e*^{−*x*} *dx* (en general), Γ(*n*) = (*n* − 1)·! (en els enters).

2 (Normal). Si *X* ∼ *N*(0, 1), aleshores per a *n* ≥ 1:

E

(

X

2
n

)
=

(
2
n
)
!

2

n
⋅
n
!

{\displaystyle {\frac {(2n)!}{2^{n}\cdot n!}}}

 i

E

(

X

2
n
−
1

)
=
0.

{\displaystyle {\frac {(2n-1)!}{2^{n-1}\cdot (n-1)!}}=0.}

 Evidentment, *N*(0, 1) és un cas particular de *N*(*μ*, *σ*²) prenent els valors *μ* = 0 i *σ*² = 1. Si *X* ∼ *N*(0, 1), aleshores *Y* = *μ* + *σX* ∼ *N*(*μ*, *σ*²). Si *Y* ∼ *N*(*μ*, *σ*²), aleshores *X* =

Y
−
μ
σ

{\displaystyle {\frac {Y-\mu }{\sigma }}}

 ∼ *N*(0, 1).

3 (χ² de Pearson). *χ*_(*n*)² ∼ Gamma(

1
2

,

n
2

{\displaystyle {\frac {1}{2}},\,{\frac {n}{2}}}

). Si *X*₁, ..., *X*_{*n*} són VAIID amb llei *N*(0, 1), aleshores *X*_{*i*}² ∼ *χ*₍₁₎² ∼ Gamma(

1
2

,

1
2

{\displaystyle {\frac {1}{2}},\,{\frac {1}{2}}}

). Consegüentment, *X*₁² + ...+ *X*_{*n*}² ∼ *G*(

1
2

,

n
2

{\displaystyle {\frac {1}{2}},\,{\frac {n}{2}}}

) ∼ *χ*_(*n*)². Siguin *X*₁, ..., *X*_{*n*}, *n* VAIID amb llei *N*(0, *σ*²), aleshores

X

1

2

+
⋯
+

X

n

2

σ

2

{\displaystyle {\frac {X_{1}^{2}+\cdots +X_{n}^{2}}{\sigma ^{2}}}}

 ∼ *χ*_(*n*)².

4 (*t*-student). Siguin *X* ∼ *N*(0, 1) i *Y* ∼ *χ*_(*n*)² dues variables aleatòries independents, aleshores

√
n
X

√
Y

{\displaystyle {\frac {\sqrt {n}X}{\sqrt {Y}}}}

 ∼ *t*_(*n*). Siguin *Y*, *X*₁, ..., *X*_{*n*}, *n* + 1 VAIID amb llei *N*(0, *σ*²), aleshores

√
n
Y

X

1

2

+
⋯
+

X

n

2

{\displaystyle {\frac {\sqrt {n}Y}{X_{1}^{2}+\cdots +X_{n}^{2}}}}

 ∼ *t*_(*n*). Tenim que

E

(
X
)
=
0

{\displaystyle E(X)=0}

 per a *n* > 1 i

Var

(
X
)
=

n

n
−
2

,

n
>
2.

{\displaystyle Var(X)={\frac {n}{n-2}},\,n>2.}

 Asimptòticament es comporta com una *N*(0, 1).

Diagrama de Venn que mostra la relació entre les propietats de la funció de densitat i la funció de risc.

5. *P*(*X* < *a*) = *F*(*a*[−]), *P*(*a* ≤ *X* ≤ *b*) = *F*(*b*) − *F*(*a*[−]), *P*(*a* < *X* ≤ *b*) = *F*(*b*) − *F*(*a*), *P*(*a* ≤ *X* < *b*) = *F*(*b*[−]) − *F*(*a*[−]), *P*(*a* < *X* < *b*) = *F*(*b*[−]) − *F*(*a*), *P*(*X* = *a*) = *F*(*a*) − *F*(*a*[−]) ≥ 0.

6 (Canvi de paràmetre). *Y* té densitat *f*_{*Y*}(*y*) = *f*_{*X*}(*g*^{−1}(*y*)) · |(g^{−1})'(*y*)| = *f*_{*X*}(*g*^{−1}(*y*))

1

|

g

′

(

g

−
1

(
y
)
)

|

{\displaystyle {\frac {1}{|g'(g^{-1}(y))|}}}

.

7. Siguin *X*, *Y* v.a. *simples* i *a*, *b* ∈ ℝ. Aleshores:

E

(
a
X
+
b
Y
)
=
a

E

(
X
)
+
b

E

(
Y
)
,

E

(
a
+
b
X
)
=
a
+
b

E

(
X
)
,

{\displaystyle E(aX+bY)=aE(X)+bE(Y),\,E(a+bX)=a+bE(X),\,}

 i si *X*, *Y* ≥ 0 i *X* ≤ *Y*, es té

E

(
X
)
≤

E

(
Y
)
.

{\displaystyle E(X)\leq E(Y).}

 Si *X*, *Y* independents amb esperança finita,

E

(
X
Y
)
=

E

(
X
)

E

(
Y
)
.

{\displaystyle E(XY)=E(X)E(Y).}

 A més, si tenim *X*₁, ..., *X*_{*n*} VAIID,

E

(

X

i

)
=

E

(

X

j

)
,

∀
i
,
j
.

{\displaystyle E(X_{i})=E(X_{j}),\,\forall i,j.}

8. Siguin

X

1

,
.
.
.
,

X

n

{\displaystyle X_{1},\ldots ,X_{n}}

 VAIID amb llei *B*(*p*) (Bernoulli), aleshores *X*₁ + ...+ *X*_{*n*} ∼ *B*(*n*, *p*) (Binomial). Siguin *X* ∼ *B*(*n*₁, *p*) i *Y* ∼ *B*(*n*₂, *p*) independents; aleshores, *X* + *Y* ∼ *B*(*n*₁ + *n*₂, *p*).

9. Sempre es verificarà

E

[

X
¯

]
=
μ

i

Var

(

X
¯

)
=

σ

2

n

,

{\displaystyle E[{\bar {X}}]=\mu \,i\,Var({\bar {X}})={\frac {\sigma ^{2}}{n}},}

 sense importar la distribució.

10. Siguin *X*, *Y* dues v.a. independents amb moments de segon ordre finits. Aleshores,

Var

(
X
+
Y
)
=
Var

(
X
)
+
Var

(
Y
)
.

{\displaystyle Var(X+Y)=Var(X)+Var(Y).}

 Interessant:

Var

(

X

(
n
)

)
=

Var

(

X

1

)

n

{\displaystyle Var(X_{(n)})={\frac {Var(X_{1})}{n}}}

 i

Var

(
a
+
b
X
)
=

b

2

Var

(
X
)
.

{\displaystyle Var(a+bX)=b^{2}Var(X).}

Cov

(
X
,
Y
)
=
E

[

(
X
−
E
(
X
)
)
(
Y
−
E
(
Y
)
)
]
.

{\displaystyle Cov(X,Y)=E[(X-E(X))(Y-E(Y))].}

11. Sigui *X* una variable aleatòria amb funció de distribució contínua. Aleshores, *Y* = *F*(*X*) ∼ *U*(0, 1). Si *X* ∼ *U*(0, 1), aleshores *Z* = −ln *X* ∼ Exp(1). Siguin *X* ∼ Gamma(*α*, *β*₁) i *Y* ∼ Gamma(*α*, *β*₂) dues variables aleatòries independents. Aleshores, *X* + *Y* ∼ Gamma(*α*, *β*₁ + *β*₂).

12 (Indicatrius).

1

A
∩
B

=
min
(

1

A

,

1

B

)
=

1

A

⋅

1

B

.

{\displaystyle \mathbf {1} _{A\cap B}=\min (\mathbf {1} _{A},\mathbf {1} _{B})=\mathbf {1} _{A}\cdot \mathbf {1} _{B}.}

1

A
∪
B

=
max
(

1

A

,

1

B

)
=

1

A

+

1

B

−

1

A
∩
B

.

{\displaystyle \mathbf {1} _{A\cup B}=\max (\mathbf {1} _{A},\mathbf {1} _{B})=\mathbf {1} _{A}+\mathbf {1} _{B}-\mathbf {1} _{A\cap B}.}

E

(

1

A

)
=
P
(
A
)
,

Var

(

1

A

)
=
P
(
A
)
(
1
−
P
(
A
)
)
.

{\displaystyle E(\mathbf {1} _{A})=P(A),\,Var(\mathbf {1} _{A})=P(A)(1-P(A)).}

13 (Txebitxev). Sigui *X* v.a. no negativa i *f* : ℝ⁺ → ℝ creixent tal que

E

(
f
(
X
)
)
<
∞
.

{\displaystyle E(f(X))<\infty .}

 Per a tot nombre real positiu *a* tal que *f*(*a*) > 0, es compleix que

P

(
X
≥
a
)
≤

E
(
f
(
X
)
)

f
(
a
)

.

{\displaystyle P(X\geq a)\leq {\frac {E(f(X))}{f(a)}}.}

14 (Jensen). Sigui *X* v.a. amb esperança finita i *g* convexa tal que

E

(
g
(
X
)
)
<
∞
.

{\displaystyle E(g(X))<\infty .}

 Aleshores,

g

(

E

(
X
)

)
≤
E
(
g
(
X
)
)
.

{\displaystyle g(E(X))\leq E(g(X)).}

15 (Model regular). Un model estadístic no és regular si, per exemple, {*x* ∈ Ω | *L*(*x*, *θ*) > 0} ⊂ Ω depèn de *θ*. En el cas unidimensional, és exponencial regular si:

$$L(x,\theta)=\exp\left\{C(\theta)\Phi(x)+D(\theta)+\Psi(x)\right\}.\;\;(1)$$

16 (Neyman-Fisher). Sigui *T* un estadístic. *T* és suficient si existeixen *ψ*(*T*(*x*), *θ*) i *h*(*x*) tals que

ℒ

(
x
,
θ
)
=
ψ
⋅
h
.

{\displaystyle {\mathcal {L}}(x,\theta)=\psi \cdot h.}

17. En un model exponencial regular, la Φ de (1) és un estadístic complet i suficient. A més,

E

θ

(
Φ
(
x
)
)
=
−

D
′
(
θ
)

C
′
(
θ
)

.

{\displaystyle E_{\theta }(\Phi (x))=-{\frac {D'(\theta)}{C'(\theta)}}.}

18 (Informació de Fisher). En un model estadístic paramètric regular (*R*), la informació de Fisher és la funció del paràmetre següent:

I

F

(
θ
)
:=

E

θ

(

|

∂

θ

ln
⁡
L
(
x
,
θ
)

|

2

)
=

E

θ

(
sc
(
θ

)

2

)

i

E

θ

(
∂

θ

ln
⁡
L
(
x
,
θ
)
)
=
0.

{\displaystyle I_{F}(\theta):=\mathbb {E} _{\theta }(|\partial _{\theta }\ln L(x,\theta)|^{2})=\mathbb {E} _{\theta }(sc(\theta)^{2})\,i\,\mathbb {E} _{\theta }(\partial _{\theta }\ln L(x,\theta))=0.}

 Assumint (*R*),

I

F

(
θ
)
=
−

E

θ

(

∂

θ

2

ln
⁡
L
(
x
,
θ
)
)
.

{\displaystyle I_{F}(\theta)=-\mathbb {E} _{\theta }(\partial _{\theta }^{2}\ln L(x,\theta)).}

Considerem un model estadístic paramètric (Ω, *ℒ*, {*P*_{*θ*}, *θ* ∈ Θ}), Θ ⊆ ℝ^{*d*}, on el paràmetre *θ* és desconegut, i *n* observacions *x*₁, ..., *x*_{*n*} d'un vector aleatori *X* = (*X*₁, ..., *X*_{*n*}) : Ω → Ω amb llei *P*_{*θ*}.

19 (Uniformement millor). Fixada una funció de pèrdua *W* i dos estadístics *T* i *S* amb funció de risc finita per a qualsevol *θ* ∈ Θ, direm que *T* és uniformement millor que *S* si *R*_{*T*}(*θ*) ≤ *R*_{*S*}(*θ*), ∀*θ* ∈ Θ.

20 (Òptim). Fixada una funció de pèrdua *W* i una classe *ℒ* d'estadístics que tenen tots funció de risc finita per a qualsevol *θ* ∈ Θ, direm que *T* és òptim dins la classe *ℒ* si

$$R_{T}(\theta)\leq R_{S}(\theta),\quad \forall\,\theta\in\Theta,\forall S\in\mathcal{E}$$

L'objectiu de l'estimació puntual és trobar estimadors òptims.

21 (Sense biaix). Direm que un estadístic integrable *T* és un estimador sense biaix de *g*(*θ*) si

E

θ

(
T
)
=
g
(
θ
)
,

{\displaystyle \mathbb {E} _{\theta }(T)=g(\theta),}

 per a tot *θ* ∈ Θ.

22 (Biaix). El biaix d'un estimador integrable *T* respecte a *g*(*θ*) és la funció *b*_{*T*}(*θ*) =

E

θ

(
T
)
−
g
(
θ
)
.

{\displaystyle \mathbb {E} _{\theta }(T)-g(\theta).}

23. La mitjana mostral

X
¯

n

=

1
n

∑

i
=
1

n

X

i

{\displaystyle {\bar {X}}_{n}={\frac {1}{n}}\sum _{i=1}^{n}X_{i}}

 és un estimador sense biaix de

E

θ

(

X

1

)
.

{\displaystyle E_{\theta }(X_{1}).}

 La variància mostral

T
=

1
n

∑

i
=
1

n

(

X

i

−
X
¯
n

)

{\displaystyle T={\frac {1}{n}}\sum _{i=1}^{n}(X_{i}-{\bar {X}}_{n})}

 és un estimador esbiaixat de

Var

θ

(

X

1

)
.

{\displaystyle Var_{\theta }(X_{1}).}

24 (Cota de Cramer-Rao). Suposem que tenim un model estadístic paramètric regular com el d'abans. Sigui *T* ∈ *ℒ*_{*F*} i considerem la funció *g*(*θ*) =

E

θ

(
T
)
.

{\displaystyle \mathbb {E} _{\theta }(T).}

 Aleshores,

Var

θ

(
T
)
≥

g
′
(
θ
)

2

I

F

(
θ
)

.

{\displaystyle Var_{\theta }(T)\geq {\frac {g'(\theta)^{2}}{I_{F}(\theta)}}.}

25 (Estimador eficient). Direm que *T* és eficient si per a tot *θ* ∈ Θ es compleix que

Var

θ

(
T
)
=

g
′
(
θ
)

2

I

F

(
θ
)

.

{\displaystyle Var_{\theta }(T)={\frac {g'(\theta)^{2}}{I_{F}(\theta)}}.}

 Tot estimador *T* ∈ *ℒ*_{*F*} eficient no té biaix i tot estimador eficient en un model (R) és UMV.

26 (Eficient). Sigui un model estadístic paramètric regular i *T* ∈ *ℒ*_{*F*} un estadístic. Són equivalents:

- T* és eficient respecte a *g*(*θ*).
- Existeix una funció λ(*θ*) tal que per a tot *θ* ∈ Θ, λ(*θ*) · ∂_{*θ*} ln *L*(*x*, *θ*) = *T*(*x*) − *g*(*θ*)

x
→
∞

q
s

{\displaystyle {\frac {x\rightarrow \infty }{qs}}}

 P(*θ*).

27 (Mètode dels moments). La llei dels grans nombres ens diu que els moments empírics convergeixen cap als moments poblacionals:

$$\hat{m}_{j}:=\frac{1}{n}\sum_{i=1}^{n}x_{i}^{j}\overset{\mathrm{qs}}{\underset{n\rightarrow\infty}{\longrightarrow}}m_{j}=\mathbb{E}_{\theta}\left(x_{1}^{j}\right).$$

Diagrama de Venn que mostra la relació entre les propietats de la funció de densitat i la funció de risc.

Propietats asimptòtiques del mètode de moments: Òbviament *k* ≥ *d*, però pot ocórrer que *k* > *d*. Aquests estimadors són fortament consistents.

28 (EMV). Un estadístic

θ
^

=

θ
^

(
x
)

{\displaystyle {\hat {\theta }}={\hat {\theta }}(x)}

 a valors en Θ s'anomena *estimador de màxima versemblança* del paràmetre *θ* si maximitza la funció de versemblança *L*(*x*, *θ*). Un EMV

θ
^

(
x
)

{\displaystyle {\hat {\theta }}(x)}

 haurà de complir les anomenades *equacions de versemblança*:

$$\partial _{i}\ln L(x,\theta)|_{\theta ={\hat {\theta }}(x)}=0,\quad i=1,\ldots ,d.$$

I la matriu:

$$\left(-\partial _{\theta _{i}\theta _{j}}\ln L(x,\theta)|_{\theta ={\hat {\theta }}(x)}\right)_{i,j=1,\ldots ,d}$$

haurà de ser definida positiva. Amb aquestes condicions obtenim

θ
^

(
x
)

{\displaystyle {\hat {\theta }}(x)}

 és un màxim local; a la pràctica, però ens faltarà confirmar que és global.

29 (Invariància funcional). Si

θ
^

=

θ
^

(
x
)

{\displaystyle {\hat {\theta }}={\hat {\theta }}(x)}

 és un EMV de *θ* en el model (Ω, *ℒ*, {*P*_{*θ*} | *θ* ∈ Θ}), aleshores *g*(

θ
^

(
x
)

{\displaystyle {\hat {\theta }}(x)}

) (bijectiva) és un EMV de

θ
¯

=

g
(
θ
)

{\displaystyle {\bar {\theta }}=g(\theta)}

. Si existeix un estimador eficient, serà l'obtingut pel mètode de la màxima versemblança.

30 (Consistent). Direm que una successió d'estimadors (*T*_{*n*})_{*n*} és consistent/fortament consistent si:

$$T_n\overset{n\rightarrow\infty}{\underset{\mathrm{qs}}{\longrightarrow}}g(\theta),\forall\theta\in\Theta.$$

$$T_n\overset{n\rightarrow\infty}{\longrightarrow}g(\theta),\;\forall\theta\in\Theta.$$

39 (Estadístic suficient). Direm que un estadístic $T : \Omega \longrightarrow \mathbb{R}^n$ és *suficient* si la llei del vector X condicionada per l'estadístic T no depèn de θ .

40 (Estadístic complet). Direm que un estadístic S és complet si per a tota funció $f : g(\Theta) \longrightarrow \mathbb{R}$ mesurable, tal que $f(S)$ és integrable, es compleix:

$$\mathbb{E}_{\theta}(f(S)) = 0, \forall \theta \in \Theta \implies f(S) = 0, \forall \theta \in \Theta, \text{ ae.} \quad (2)$$

41 (IC per a la mitjana amb variància coneguda). En un exemple ja hem obtingut:

$$S(x) = \left[\bar{x}_n - \eta_{\alpha} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x}_n + \eta_{\alpha} \cdot \frac{\sigma}{\sqrt{n}} \right],$$

amb $\nu([- \eta_{\alpha}, \eta_{\alpha}]) = \alpha$, on ν és la llei $N(0,1)$.

42 (IC per a la mitjana amb variància desconeguda). Considerem una mostra aleatòria simple de mida n d'una variable aleatòria amb llei normal $N(\mu, \sigma^2)$ amb paràmetres μ, σ desconeguts, de la qual volem donar un interval de confiança per a la mitjana μ . Tenim la funció pivotant següent:

$$\nu \sim \pi(x, \mu) = \sqrt{n-1} \cdot \frac{\bar{x}_n - \mu}{s_n} \sim t_{(n-1)}.$$

Com que una t de Student és simètrica al voltant del zero, escollim un $\eta_{\alpha} > 0$ tal que $\nu([- \eta_{\alpha}, \eta_{\alpha}]) = \alpha$. Aleshores:

$$P_{\theta} \left(x \in \mathbb{R}^n, \; -\nu_{\alpha} \leq \sqrt{n-1} \cdot \frac{\bar{x}_n - \mu}{s_n} \leq \nu_{\alpha} \right) = \alpha.$$

Per tant, l'interval de confiança per μ és:

$$S(x) = \left[\bar{x}_n - \eta_{\alpha} \cdot \frac{s_n}{\sqrt{n-1}}, \bar{x}_n + \eta_{\alpha} \cdot \frac{s_n}{\sqrt{n-1}} \right].$$

43 (IC per a la variància). Considerem la funció pivotant:

$$\nu \sim \pi(x, \sigma^2) = \frac{ns_n^2}{\sigma^2} \sim \chi_{(n-1)}^2.$$

Com que una χ^2 de Pearson no és simètrica, escollim dos reals positius $\zeta_{\alpha} < \eta_{\alpha}$ tals que:

$$P_{\theta} \left(x \in \mathbb{R}^n \mid \frac{ns_n^2}{\sigma^2} \leq \zeta_{\alpha} \right) = P_{\theta} \left(x \in \mathbb{R}^n \mid \eta_{\alpha} \leq \frac{ns_n^2}{\sigma^2} \right) = \frac{1-\alpha}{2}.$$

Així l'interval de confiança per a la variància σ^2 és $S(x) = [\frac{ns_n^2}{\eta_{\alpha}}, \frac{ns_n^2}{\zeta_{\alpha}}]$.

44 (Radi de confiança per a la mitjana i la variància). Tenim que:

$$\nu \sim \pi(x, \theta) = \left(\sqrt{n} \frac{\bar{x}_n - \mu}{\sigma}, \frac{ns_n^2}{\sigma^2} \right)$$

és una funció pivotant amb lleis normal $N(0,1)$ i χ_{n-1}^2 , respectivament i, a més, independents. S'han de trobar $\zeta_{\alpha}, \eta_{\alpha}, \kappa_{\alpha} > 0$ tals que $\eta_{\alpha} < \kappa_{\alpha}$ i:

$$P_{\theta} \left(x \in \mathbb{R}^n \mid -\zeta_{\alpha} \leq \sqrt{n} \frac{\bar{x}_n - \mu}{\sigma} \leq \zeta_{\alpha}, \; \eta_{\alpha} \leq \frac{ns_n^2}{\sigma^2} \leq \kappa_{\alpha} \right) = \alpha.$$

Existeixen moltes possibilitats per determinar aquests tres valors, per exemple, denotant $\nu_1 = \sim N(0,1)$ i $\nu_2 \sim \chi_{n-1}^2$, els podem escollir de manera que es compleixin:

$$\nu_1([- \zeta_{\alpha}, \zeta_{\alpha}]) = \sqrt{\alpha} \text{ i } \nu_2([0, \eta_{\alpha}]) = \nu_2([\kappa_{\alpha}, \infty)) = \frac{1-\sqrt{\alpha}}{2}.$$

Aleshores, la regió de confiança per (μ, σ^2) serà:

$$S(x) = \left[\bar{x}_n - \zeta_{\alpha} \frac{\sigma}{\sqrt{n}}, \bar{x}_n + \zeta_{\alpha} \frac{\sigma}{\sqrt{n}} \right] \times \left[\frac{ns_n^2}{\kappa_{\alpha}}, \frac{ns_n^2}{\eta_{\alpha}} \right].$$

45 (Raó de variàncies). Un resultat previ ens dona una funció pivotant:

$$\nu \sim \pi \left(x, y, \frac{\sigma_1^2}{\sigma_2^2} \right) = \frac{n_1 s_{n_1}^2 (n_2 - 1) \sigma_2^2}{n_2 s_{n_2}^2 (n_1 - 1) \sigma_1^2} = \frac{\tilde{s}_{n_1}^2 \sigma_2^2}{\tilde{s}_{n_2}^2 \sigma_1^2} \sim F_{n_1-1, n_2-1}.$$

Com que una F de Fisher no és simètrica, per trobar l'interval de confiança buscarem dos nombres reals positius $\zeta_{\alpha}, \eta_{\alpha}$ tals que:

$$\nu([0, \zeta_{\alpha}]) = \frac{1-\alpha}{2} \text{ i } \nu([\eta_{\alpha}, \infty)) = \frac{1-\alpha}{2}.$$

Per tant, l'interval per a la raó és $S(x) = \left[\frac{\tilde{s}_{n_1}^2}{\eta_{\alpha} \tilde{s}_{n_2}^2}, \frac{\tilde{s}_{n_1}^2}{\zeta_{\alpha} \tilde{s}_{n_2}^2} \right]$.

46 (IC per a la diferència de mitjanes amb la mateixa variància desconeguda). Per diferents resultats, per exemple, perquè

$$\bar{X}_n - \bar{Y}_n \sim N \left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1}, \frac{\sigma_2^2}{n_2} \right),$$

tenim que

$$\frac{\bar{x}_{n_1} - \bar{y}_{n_2} - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim N(0,1) \\ \frac{n_1 s_{n_1}^2}{\sigma^2} + \frac{n_2 s_{n_2}^2}{\sigma^2} = \frac{\sum_{i=1}^{n_1} (x_i - \bar{x}_{n_1})^2}{\sigma^2} + \frac{\sum_{i=1}^{n_2} (y_i - \bar{y}_{n_2})^2}{\sigma^2} \sim \chi_{(n_1+n_2-2)}^2$$

són independents. Aleshores, per les propietats de la t -Student la funció següent és pivotant:

$$\nu \sim \pi(x, y, \mu_1 - \mu_2) \\ = \frac{\bar{x}_{n_1} - \bar{y}_{n_2} - (\mu_1 - \mu_2)}{\sqrt{n_1 s_{n_1}^2 + n_2 s_{n_2}^2}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} \sim t_{(n_1+n_2-2)}.$$

Podem escollir un real positiu ζ_{α} tal que $\nu([- \zeta_{\alpha}, \zeta_{\alpha}]) = \alpha$ i, aleshores, obtenim l'interval de confiança per a $\mu_1 - \mu_2$ següent

$$S(x) = \left[\bar{x}_{n_1} - \bar{y}_{n_2} - \zeta_{\alpha} \sqrt{\frac{(n_1 + n_2) (n_1 s_{n_1}^2 + n_2 s_{n_2}^2)}{n_1 n_2 (n_1 + n_2 - 2)}}, \right. \\ \left. \bar{x}_{n_1} - \bar{y}_{n_2} + \zeta_{\alpha} \sqrt{\frac{(n_1 + n_2) (n_1 s_{n_1}^2 + n_2 s_{n_2}^2)}{n_1 n_2 (n_1 + n_2 - 2)}} \right].$$

47 (IC per a la diferència de mitjanes amb diferents variàncies desconegudes). En aquest cas no tenim una resolució exacta del problema i el que es fa és donar solucions aproximades. Nosaltres donarem alguns breus comentaris extrets del llibre de Vélez i García. Si la mida de les mostres no és gaire petita ($n_1, n_2 \geq 15$) es substitueix σ_1^2 i σ_2^2 per les variàncies mostrals corregides respectives, obtenint que

$$\frac{\bar{x}_{n_1} - \bar{y}_{n_2} - (\mu_1 - \mu_2)}{\sqrt{\frac{\tilde{s}_{n_1}^2}{n_1} + \frac{\tilde{s}_{n_2}^2}{n_2}}}$$

es comportarà aproximadament com una normal $N(0,1)$. En canvi, en el cas que la mida d'una mostra sigui petita, s'empra que la quantitat anterior es comporta aproximadament com una $t_{(n)}$ on n és l'enter més pròxim a:

$$\frac{\left(\frac{\tilde{s}_{n_1}^2}{n_1} + \frac{\tilde{s}_{n_2}^2}{n_2} \right)^2}{\frac{1}{n_1+1} \left(\frac{\tilde{s}_{n_1}}{n_1} \right)^2 + \frac{1}{n_2+1} \left(\frac{\tilde{s}_{n_2}}{n_2} \right)^2}.$$

48 (Intervals de confiança asimptòtics). Suposem una successió d'estadístics T_n amb moment de segon ordre finit ($\text{Var}_{\theta}(T_n) \ll \infty$), complint que $\mathbb{E}_{\theta}(T_n) = g(\theta)$ i amb el comportament asimptòtic següent: $\frac{T_n - g(\theta)}{\sqrt{\text{Var}_{\theta}(T_n)}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} N(0,1)$. Si la mida de la mostra n és suficientment gran, podem donar un interval de confiança de $g(\theta)$ utilitzant l'aproximació d'aquest quocient per la distribució normal. És a dir:

$$P_{\theta} \left(-\eta_{\alpha} \leq \frac{T_n - g(\theta)}{\sqrt{\text{Var}_{\theta}(T_n)}} \leq \eta_{\alpha} \right) = \alpha.$$

Pel que:

$$T_n - \eta_{\alpha} \sqrt{\text{Var}_{\theta}(T_n)} \leq g(\theta) \leq T_n + \eta_{\alpha} \sqrt{\text{Var}_{\theta}(T_n)}.$$

49. Sigui (x_1, x_2, \dots, x_n) vàlid amb densitat $f_{\beta}(x) = \frac{1}{4^{\beta-1}} \mathbb{1}_{[1,4^{\beta}]}$ amb $\beta > \frac{1}{4}$.

- És un model regular?
- Troba un estadístic suficient i complet.
- Construeix un estimador sense biaix a partir de l'EMV de β , $\hat{\beta}$.
- Construeix un estimador sense biaix a partir de l'estimador pels moments de β , $\tilde{\beta}$.
- Troba el UMV.

Proof. 1. Tenim que $L(x, \beta) = \frac{1}{(4^{\beta-1})^n} \mathbb{1}_{[\frac{x_{(n)}}{4}, \infty)}(\beta)$. Veiem que el model no és regular perquè $L = 0$ si $\beta < \frac{x_{(n)}}{4}$ per tant no es satisfà la primera condició de regularitat.
2. Per Neyman-Fisher, $T(x) = x_{(n)}$ és suficient.

- L'estimador demanat ve donat per $\hat{\beta} = \frac{x_{(n)}}{4}$ i tenim que $E_{\beta}(\hat{\beta}) = E_{\beta}(\frac{X_{(n)}}{4}) = \frac{n}{4(4^{\beta-1})^n} \int_1^{4^{\beta}} (z-1)^{n-1} z \, dz = \frac{1+4n\beta}{4(n+1)}$ i si diem $\hat{\beta}^* = \beta$ i $\hat{\beta} = E_{\beta}(\hat{\beta})$ i aïllem tenim un estimador sense biaix $\hat{\beta}^* = \frac{4(n+1)\hat{\beta}-1}{4n}$.
- Ara utilitzem $E(X_1) = \int_1^{4^{\beta}} \frac{x}{4^{\beta-1}} \, dx = \frac{4^{\beta}+1}{4}$ i ens queda $\tilde{\beta} = \frac{2\bar{x}-1}{4}$.
- El UMV es $\hat{\beta}^*$ ja que no té biaix i es funció de l'estadístic suficient i complet $T = x_{(n)}$.

□

50. Sigui $n = 10$, hem obtingut $x_{(1)} = -1, x_{(10)} = 2$. Les observacions son vàlid amb densitat $f(x, \theta) = \frac{3}{2\theta} \mathbb{1}_{[-\frac{\theta}{3}, \frac{\theta}{3}]}$.

- Troba la llei de $|X|$.
- Troba una funció pivotant que depengui de $max(|X_1|, \dots, |X_n|)$.
- Troba un interval de confiança de 0.95 basat en EMV.

Proof. 1. Si $Y = |X|$ i $y \in [0, \frac{\theta}{3}]$. La funció de distribució per $y \in [0, \frac{\theta}{3}]$ és $P(|Y| \leq y) = P(|X| \leq y) = P(-y \leq X \leq y) = \frac{3}{2\theta} \int_{-y}^y \, dx = \frac{3y}{\theta}$. Si $y < 0$ aleshores val 0, si $y > \frac{\theta}{3}$ aleshores és 1. Com es continua i derivable aleshores $f_Y(y) = \frac{3}{\theta} \mathbb{1}_{[0, \frac{\theta}{3}]}(y)$. Això és $Y \sim U(0, \frac{\theta}{3})$.
2. Gràcies a l'apartat *a* tenim $\frac{|X|}{\theta/3} \sim U(0,1)$ i aleshores $\frac{3}{\theta} max(|X_1|, \dots, |X_n|) \sim max(U_1, U_2, \dots, U_n)$ on $U_i \sim u(0,1)$ independents.
3. Tenim $L(x, \theta) = (\frac{3}{2\theta})^n \prod_{i=1}^n \mathbb{1}_{[-\frac{\theta}{3}, \frac{\theta}{3}]}(x_i)$. Però $-\frac{\theta}{3} \leq x_i \leq \frac{\theta}{3}$ implica que $|x_i| \leq \frac{\theta}{3}$ per tant si escrivim $|x|_{(n)} = max(|x_1|, \dots, |x_n|)$ tenim $L(x, \theta) = (\frac{3}{2\theta})^n \mathbb{1}_{3|x|_{(n)}, \infty)}(\theta)$. D'aquesta manera el EMV és $\hat{\theta}(x) = 3|x|_{(n)}$. Considerant les variables $Y_i = \frac{3|X_i|}{\theta}$ tenim $Y_i \sim U(0,1)$ i aleshores $\frac{\tilde{\theta}}{\theta} = \frac{3}{\theta} |X|_{(n)} = max(\frac{3}{\theta} |X|_{(1)}, \dots, \frac{3}{\theta} |X|_{(n)}) = max(Y_1, \dots, Y_n)$ te una llei independent de θ . Aleshores $\frac{\tilde{\theta}}{\theta}$ té densitat donada per $f_{\frac{\tilde{\theta}}{\theta}}(u) = nu^{n-1} \mathbb{1}_{(0,1)}(u)$. Podem buscar k tal que $P(k \leq \frac{\tilde{\theta}}{\theta} \leq 1) = 0.95$. Això es $1 - k^n = 0.95$ i per tant $k = \sqrt[n]{0.05}$. En el nostre cas, amb $n = 10$ és $k = 0.74$. Ara tenim $0.74 \leq \frac{\tilde{\theta}}{\theta} \leq 1$, i per tant, $\tilde{\theta} \leq \theta \leq \frac{\tilde{\theta}}{0.74}$. Tenint en compte que $\widehat{\theta}(x) = 3|x|_{(n)}$ i que $x_{(1)} = -1, x_{(10)} = 2$ tenim que $\theta(x) = 3 \cdot 2 = 6$ i ens queda l'interval $6 \leq \theta \leq \frac{6}{0.74} \approx 8.1$.
□

51. Suposant que el contingut de nicotina dels cigarrets de determinada marca segueix una distribució $N(30, \sigma^2)$. Agafem a l'atzar deu cigarrets d'aquesta marca i obtenim:

$$\frac{1}{10} \sum_{i=1}^n (X_i - 30)^2 = 12.4.$$

Trobeu un interval de confiança per a σ amb un nivell de confiança de 0.9.

Proof. Tenim una mostra d'una variable aleatòria X amb distribució normal de mitjana $\mu = 30$ i σ^2 desconeguda. Tenim que $\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi_{(n)}^2$. Està clar que $\frac{X-30}{\sigma}$ té una distribució normal estàndard. Per tant:

$$T := \sum_{i=1}^n \left(\frac{X_i - 30}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - 30)^2$$

és un estadístic amb la distribució $\chi_{(n)}^2$ de Pearson, amb n graus de llibertat. Observem que T és una funció pivotant perquè la seva llei no depèn del paràmetre σ^2 . En aquest cas, assumim $n = 10$ i, aleshores, podem calcular a, b tals que $P(a \leq T \leq b) = P(a \leq \chi_{(10)}^2 \leq b) = 0.9$.

$$P(\chi_{(10)}^2 \leq a) = 0.05 \implies a = 3.94$$

$$P(\chi_{(10)}^2 \leq b) = 0.95 \implies b = 18.30$$

Volem arribar a demostrar que l'interval observat és $[\frac{124}{18.30}, \frac{124}{3.94}] = [6.78, 31.47]$. Efectivament, tenim que:

$$a \leq \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \leq b \iff \frac{\sum_{i=1}^n (X_i - \mu)^2}{b} \leq \sigma^2 \leq \frac{\sum_{i=1}^n (X_i - \mu)^2}{a}.$$

En el nostre cas tenim que $\sum_{i=1}^n (X_i - 30)^2 = 12.4 \cdot 10 = 124$, pel que l'interval de confiança resulta:

$$I_{0.9}(\sigma^2) = \left[\frac{\sum_{i=1}^n (X_i - 30)^2}{b}, \frac{\sum_{i=1}^n (X_i - 30)^2}{a} \right] = \left[\frac{124}{18.30}, \frac{124}{3.94} \right] = [6.78, 31.47].$$

Si volem un interval per a σ tenim $I_{0.9}(\sigma) = [\sqrt{6.78}, \sqrt{31.47}] = [2.60, 5.61]$.
□