

Cinc Cèntims

TALLER DE NOUS USOS DE LA INFORMÀTICA

Mario VILAR

7 de novembre de 2024



UNIVERSITAT DE
BARCELONA

ÍNDEX

1	Introducció	2
2	Recomanadors	5
3	Classificació	8
4	El problema dels ítems freqüents	10
5	Hipòtesis, inferències i A-B testing	13

INTRODUCCIÓ

Definició 1.1 (Optimització). En matemàtiques, estadística, ciències de la computació o economia, el concepte d'optimització correspon al procés de selecció del millor element (o conjunt d'elements), respecte d'un criteri determinat (amb o sense restriccions), entre un conjunt d'elements disponibles.

1. Per funcions unimodals contínues podem usar mètodes basats en la derivada (o el gradient). En aquest cas tenim garanties sobre la solució trobada.
2. Per funcions multimodals contínues podem usar mètodes estocàstics basats en les derivades, però no hi ha garanties sobre la solució trobada (pot ser un extrem local).
3. Per funcions discretes o amb valors enters, hi ha mètodes específics. Per exemple, l'algorisme del simplex.
4. També hi ha mètodes estocàstics que poden servir per qualsevol tipus de funció. Per exemple, els algorismes genètics són una bona solució pel problema TSP.

Durant tot aquest curs representarem els conjunts de dades de elements en forma matricial, amb valors definits sobre característiques. Suposem de moment que totes les característiques de les dades són numèriques (hi ha mètodes per transformar-les a numèriques quan no ho són).

L'objectiu de molts mètodes d'anàlisi de dades és convertir aquesta matriu de dades en un model.

Definició 1.2 (Model). Un model és una família de funcions f_θ que depèn de $\theta = (\theta_1, \dots, \theta_d) \in \Theta$, $\Theta \subset \mathbb{R}^d$ i que representa fidelment i de forma compacte algun aspecte de la matriu de dades.

Observació 1.3. El valor mitjà d'una (o d'un conjunt) característica la representa de forma compacte i aproximada, però és un estadístic, no un model (perquè no depèn de cap paràmetre).

Proposició 1.4. Els mètodes d'optimització serveixen per buscar els valors dels paràmetres $\theta_1, \dots, \theta_d$ que minimitzen els errors de representació del model.

Demostració.

1. Definirem una família de funcions, el model, que pugui representar el conjunt de dades.
2. Definirem una mesura de l'error que cometem al representar cada fila de la matriu de dades amb aquest model. Sumarem tots els termes de mesura d'error per obtenir una funció de pèrdua, la qual simplement representa l'error que cometem en proposar un valor concret com a valor estimat del nostre paràmetre. Formalment,

$$\begin{aligned} W : \mathbb{R}^k \times \Theta &\longrightarrow \mathbb{R}^+ \\ (t, \theta) &\longmapsto W(t, \theta) \end{aligned} \quad t \in \mathbb{R}^k, \theta \in \Theta \subset \mathbb{R}^d.$$

3. Finalment, usarem un algorisme d'optimització per trobar els paràmetres $\theta_1, \dots, \theta_n$ òptims, és a dir, els que fan que sigui el més petit possible. ■

Exemple 1.5. Suposem que les nostres dades representen els pisos de Barcelona amb dues característiques, els metres quadrats (X) i el preu de venda d'aquests pisos (Y). Enlloc de tenir una gran taula amb moltes files, podríem usar un model lineal, $y = ax + b$, que només depèn de 2 paràmetres a i b , que representi el preu en funció dels metres quadrats. Evidentment, a la realitat, per trobar un bon model, cal que X representi tots els aspectes relacionats amb el preu d'un pis: barri, alçada, carrer, habitacions, etc, i per tant el model ha de tenir més característiques i consegüentment més paràmetres:

$$y = a_1x_1 + \dots + a_nx_n + a_{n+1}.$$

Per la mesura de l'error triem, per exemple $(ax_i + b - y_i)^2$, on x_i, y_i són dades de la fila i que representen els m^2 i el preu del pis i (d'un conjunt amb N pisos). Sumarem tots els termes de mesura d'error per obtenir un valor $L(f)$ (que anomenarem funció de pèrdua).

$$L(f) = \frac{1}{N} \sum_{i \in D} (ax_i + b - y_i)^2.$$

Finalment, usarem un algorisme d'optimització per trobar els paràmetres a, b òptims; els que fan que L sigui el més petit possible:

$$\arg_{\min}^{(a,b)} \frac{1}{N} \sum_{i \in D} (ax_i + b - y_i)^2.$$

Aquest model representa el conjunt de dades des del punt de vista que si sabem els metres quadrats, podem obtenir el preu (aproximat) aplicant una fórmula, sense necessitat de tenir la taula.

Observació 1.6. Aplicar un algorisme d'optimització directament pot ser perillós: podem trobar un model que approximi molt bé les dades i que predigui molt malament. Aquest fenomen es diu sobre-estimació (overfitting). Si l'objectiu del nostre model no és simplement representar el conjunt de dades sinó que volem generalitzar (predir el valor de dades que no estan al conjunt d'aprenentatge), ho hem de controlar!

En general aprendre de les dades vol dir inferir (construir de baix cap a dalt, de les dades cap el model) un model que ens permeti representar-les de forma compacte i també ens permeti generalitzar.

Definició 1.7 (Aprentatge supervisat). Donat un conjunt de dades (x_i) , $1 \leq i \leq n$, volem construir una funció f tal que $y_i = f(x_i)$ és una representació compacta (més simple, de menys dimensions, etc.) del conjunt, que ens permeti realitzar tasques.

Definició 1.8 (Aprentatge supervisat). Donat un conjunt de dades etiquetades (x_i, y_i) , $1 \leq i \leq n$, on la variable y representa una etiqueta o valor d'interès, volem construir una funció f tal que quan rebem una nova dada x_j , no vista anteriorment, el càlcul de $y_j = f(x_j)$ sigui probablement correcte.

Definició 1.9 (Cross-validation). Aquesta estratègia consisteix a dividir en dos subconjunts complementaris el conjunt de dades D , determinant el model sobre un subconjunt (anomenat dades d'entrenament o *training set*), i *validant-lo* en l'altre subconjunt (anomenat dades de prova o *test set*). El model només s'ajusta amb el

conjunt de dades d'entrenament i a partir d'aquí calcula els valors de sortida per al conjunt de dades de prova (valors que no ha analitzat abans).

Definició 1.10 (Descens del gradient). Una gran part dels algorismes estan basats en la resolució iterativa que minimitza:

$$\arg_{\min}^w \frac{1}{N} \sum_{i \in D} (f_w(x_i) - y_i)^2.$$

Podem repetir la següent estratègia (algorisme de descens del gradient):

1. Col·locar-se en una solució potencial aleatòria (un valor aleatori de v).
2. Calcular el vector gradient en aquell punt.
3. Fer un petit pas (variar el valor de v) en la direcció (contrària) del vector gradient.
4. La cerca s'acaba quan el vector gradient és zero (o molt petit) o quan el canvi en el valor de f és molt petit. En aquests casos, presumiblement hem trobat un mínim.
5. Si la funció és unimodal (conté un únic mínim), hem trobat la nostra solució. Sinó, pot ser que estem en un mínim local que no sigui global.
6. En general, per funcions multimodals d'alta dimensió, és impossible saber si el mínim que hem trobat és el mínim global.

Definició 1.11 (pas). Una funció que variï el valor de v en la direcció contrària del gradient. La mida del pas és un aspecte delicat: si és massa petita avançarem massa lentament; si és massa gran, podem perdre el màxim (mínim) que estem buscant.

Algoritme 1.12.

1. *Inicialitza els paràmetres: Comença inicialitzant els paràmetres del model, θ , de manera aleatòria: θ_0 .*
2. *Defineix una funció de cost $L(x, y, \theta)$ que mesuri quan bé ho fa el model amb els paràmetres θ . L'objectiu és minimitzar aquesta funció.*
3. *Calcula el gradient de la funció de cost $L'(x, y, \theta)$ respecte de cada paràmetre. El gradient apunta a la direcció de l'augment més pronunciat de la funció de cost.*
4. *Actualitza els paràmetres: Ajusta els paràmetres del model en la direcció contrària del gradient per reduir el cost. Això es fa utilitzant la següent fórmula d'actualització (α és la taxa d'aprenentatge, que controla la mida del pas en cada iteració. És un hiperparàmetre que s'ha de fixar prèviament i pot variar segons el problema):*

$$\theta_{i+1} = \theta_i - \alpha \cdot L'(x, y, \theta_i).$$

Repeteix: Repeteix els passos 3 i 4 durant un nombre fix d'iteracions, fins que els canvis en els paràmetres es tornen molt petits o fins quan la funció de cost arriba a un mínim dins d'una tolerància prèviament definida.

Si el volum de dades és molt gran, f és costosa i hem de fer moltes iteracions, aquesta estratègia no és viable. Podem usar la tècnica *Stochastic Gradient Descend* (SGD), que consisteix en calcular el gradient (i fer un pas en la direcció del mínim) amb la diferència que l'estimació serà sobre *una única dada* (o d'un conjunt petit de dades o minibatch) i que iterarem sobre les dades en un ordre aleatori.

Observació 1.13. Perquè és útil la derivada per optimitzar una funció? La derivada d'una funció proporciona informació sobre com canvia la funció en un punt determinat.

1. Els màxims i mínims d'una funció corresponen als punts on la seva derivada s'anul·la. Això és essencial per optimitzar funcions, ja que sovint estem interessats en trobar els valors màxims o mínims d'una funció en un cert domini.
2. La derivada també proporciona informació sobre la pendent d'una funció en un punt concret. En l'optimització, és crucial entendre com canvia la funció en diferents punts, i la derivada ens diu si la funció està augmentant o disminuint en aquest punt.

El gradient de la funció f , que és un vector format per les derivades parcials de la funció, ens dóna la direcció en la qual la funció creix més ràpidament.

$$\nabla f = \left(\frac{\partial f}{\partial v_1}, \dots, \frac{\partial f}{\partial v_n} \right).$$

2

RECOMANADORS

Definició 2.1 (Recomanador). Un recomanador és un sistema de filtrat d'informació que té per objectiu posar en correspondència un usuari amb ítems (que possiblement no coneix) en funció d'una estimació de les seves preferències i interessos a partir d'una mostra (expressats de forma directa o indirecta).

La cerca és el que fas quan busques alguna cosa que saps que existeix; el descobriment és quan alguna cosa que tu no sabies que existia (o no sabies com cercar) et troba.

C és el conjunt de tots els usuaris i S és el conjunt de tots els ítems que es poden recomanar. Els espais C i S poden tenir una cardinalitat molt gran. $u : C \times S \rightarrow \mathbb{R}^+$ és una funció (desconeguda, però de la qual tenim una petita mostra) que assigna el grau d'utilitat o d'interès que pot tenir un determinat ítem per un determinat usuari.

Definició 2.2 (Problema de la recomanació). El problema de la recomanació és determinar l'ítem $s_c \in S$ (s_c ha de formar part dels ítems que no coneix) per a cada usuari $c \in C$. Aquest s_c maximitza la funció d'utilitat: $s_c = \operatorname{argmax}_{s \in S} u(c, s)$, per a tot $c \in C$. Discretitzem la funció d'utilitat com una matriu U :

U	s_1	s_2	$\dots$	s_n
c_1	u_{11}	u_{12}	$\dots$	u_{1n}
c_2	u_{21}	u_{22}	$\dots$	u_{2n}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
c_n	u_{n1}	u_{n2}	$\dots$	u_{nn}

- Els elements de C es poden caracteritzar amb un perfil, que inclou característiques definitòries de l'usuari.

- Els elements de S també es poden caracteritzar amb un conjunt de característiques definitòries de l'ítem.

U no està definida per tots els elements; només en tenim una mostra i, per tant, hem d'**extrapolar** els seus valors: estimar quin valor d'utilitat tenen els ítems que són desconeguts per cada usuari. Les extrapolacions (estimar un valor per cada element no conegut de la matriu) es poden fer de diverses maneres, però la més important és estimant una funció/model d'utilitat $u'(C, S)$ de manera que optimitzi algun criteri relacionat amb l'error sobre la part d' U que coneixem.

Definició 2.3 (Error empíric). Error sobre la part d' U que coneixem.

Definició 2.4 (Recomanacions col·laboratives). Recomanarem a un usuari els ítems útils, entenent que la utilitat és construeix a partir de l'anàlisi de la matriu U . Podem construir solucions heurístiques o basades en optimització. Podem distingir dos tipus de recomanacions col·laboratives:

1. Mètodes col·laboratius basats en la semblança d'usuaris (basada en l'anàlisi d' U). La utilitat $u'(c, s)$ de l'ítem per l'usuari és:
 - 1.1. $u(c, s)$, si l'usuari l'ha valorat (i tenim el valor a U).
 - 1.2. Si no, una estimació construïda a partir de les utilitats assignades a l'ítem pels usuaris de la nostra base de dades que l'han valorat, ponderades segons la semblança entre els c_i i c . Dos usuaris són semblants si tendeixen a valorar els ítems de la mateixa manera.
 - 1.3. La mesura de semblança entre dos usuaris està definida sobre el conjunts d'ítems que ambdós han valorat. Es pot definir com una distància entre vectors.
2. Mètodes col·laboratius basats en la semblança d'ítems (basada en l'anàlisi d' U). Especialment útils quan no tenim molta informació de l'usuari a la matriu.
 - 2.1. La utilitat $u'(c, s)$ de l'ítem s per l'usuari c s'estima a partir de les utilitats $u(c, s_i)$ assignades per l'usuari c als ítems s_i , ponderades segons la semblança entre els ítems.
 - 2.2. Dos ítems seran semblants si han estat valorats de la mateixa forma per un nombre important d'usuaris.

Definició 2.5 (Coeficient de correlació de Pearson). El coeficient de correlació de Pearson calcula una mesura de l'ajust d'un conjunt de punts a una recta. Funciona millor que la distància euclidiana si les components no estan ben calibrades. La seva fórmula és:

$$r(X, Y) = \frac{\sum_{i=1}^m (x_i - \hat{x}_i)(y_i - \hat{y}_i)}{\sqrt{\sum_{i=1}^m (x_i - \hat{x}_i)^2} \cdot \sqrt{\sum_{i=1}^m (y_i - \hat{y}_i)^2}}.$$

Definició 2.6 (Distància calibrada). Direm que una mesura de «distància» entre dos vectors està calibrada si una distància de 2 representa dues vegades una distància de 1.

2.7. Donada una definició de distància entre usuaris, podríem pensar en una proposta inicial (molt simple) de recomanació a un usuari A : Podem buscar un usuari semblant a A , A' , i recomanar un ítem que hagi agradat a A' (un ítem amb utilitat molt alta per A') i que A no hagi vist.

- Solució heurística: fer una ponderació de les puntuacions amb tots els usuaris. La suma de les puntuacions ponderades es normalitza per eliminar el biaix introduït. No està basat en optimitzar numèricament l'error empíric.

Propietat 2.8 (de la recomanació col·laborativa basada en ítems).

1. Si calculem la matriu U^t , llavors, aplicant els mateixos mètodes que hem vist pels usuaris podem fer una recomanació basada en ítems i no en usuaris.
2. Semblança amb la col·laboració basada en usuaris: hem de processar tota la taula.
3. Diferència amb la col·laboració basada en usuaris: les comparacions entre ítems canvien en el temps més lentament que les comparacions entre usuaris i, per tant, es més estable, però és menys precisa des del punt de vista de l'error empíric.
4. Funciona millor que el basat en usuaris en bases de dades esparses i el basat en usuaris funciona millor en bases de dades denses.

Definició 2.9 (Recomanacions no col·laboratives). Basades en el contingut. Recomanarem a l'usuari ítems útils, entenent que la utilitat és construeix a partir de la descripció del contingut dels ítems.

Resum de recomanació

1. Recomanació col·laborativa basada en usuaris:
 - 1.1. Identificar I , el conjunt d'ítems que ha valorat l'usuari objectiu.
 - 1.2. Identificar N , el conjunt d'usuaris que han valorat 1 o més ítems del conjunt I .
 - 1.3. Calcular la semblança de cada usuari d' N a l'usuari objectiu.
 - 1.4. Predir les valoracions de l'usuari objectiu per I^c , el conjunt d'ítems que no ha valorat.
 - 1.5. Recomanar els n productes de I^c amb valoració més alta.
2. Recomanació col·laborativa basada en ítems:
 - 2.1. Identificar U , el conjunt d'usuaris que han valorat l'ítem objectiu.
 - 2.2. Identificar N , el conjunt d'ítems que han estat valorat pels usuaris de U .
 - 2.3. Calcular la semblança entre cada element de N i l'ítem objectiu.
 - 2.4. Predir la valoració de l'ítem objectiu.

El principal problema és com tractar els nous usuaris i els nous ítems (*cold start problem*).

Definició 2.10 (Recol·lecció explícita). Demanar explícitament a un usuari que valori un ítem concret. Per exemple, demanar a un usuari avaluar un ítem segons una escala numèrica.

1. Millor personalització però no sempre és possible.
2. Esbiaixada cap a usuaris polaritzats.

Definició 2.11 (Recol·lecció implícita). Recollir alguna mètrica de l'usuari que ens doni informació sobre els ítems que consulta. Per exemple, anotar els ítems que consulta a la base de dades, analitzar els períodes de temps d'aquestes consultes.

1. Més simple i és menys intrusiva. No permet afinar la personalització.

2. No té el problema de la polarització.

2.12 (Col·laboratiu vs. no col·laboratiu).

- Els sistemes col·laboratiu purs usen exclusivament la matriu de puntuacions dels usuaris, però és evident que podem millorar-ho si tenim informació de l'usuari i dels ítems.
- Els mètodes no col·laboratiu basats en el contingut recomanen ítems a partir de comparar descripcions del contingut de cada ítem a representacions dels continguts dels ítems que sabem interessar a l'usuari.

La qualitat d'un sistema de recomanació es pot avaluar comparant les recomanacions que fa el mètode desenvolupat amb les avaluacions d'un conjunt de test.

Definició 2.13 (Mètrica de precisió de la predicció). La mètrica més usada és l'error absolut mig, que es defineix com la diferència absoluta mitja entre les avaluacions predites i les reals:

$$MAE = \frac{\sum_{i,j} |u'(i, j) - u(i, j)|}{N},$$

on $u'(i, j)$ és l'avaluació predita de l'usuari i per l'ítem j , $u(i, j)$.

3

CLASSIFICACIÓ

Definició 3.1. In machine learning, classification is the problem of classifying instances $(x_1, \dots, x_n)$ into two or more classes $(z_1, \dots, z_K)$.

This problem can be solved by training a model $f_w(x)$ that produces a numeric output $z \in \mathbb{R}^K$ that represents a vector of classification scores (not necessarily probabilities) for K classes. Per convertir-les a probabilitats utilitzem **softmax**:

$$\text{softmax}(z) = \frac{e^z}{\sum_{j=0}^{K-1} e^{z_j}}.$$

Softmax has a better behavior with respect to Stochastic Gradient Descend than simple normalization!

Exemple 3.2 (Cross-entropy). Given a dataset (x_i, y_i) with n samples, with features $x \in \mathbb{R}^m$, and labels $y \in \{0, 1\}$, the cross-entropy loss is defined as:

$$CE = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)),$$

where $\hat{y}$ is the predicted probability for class 1 and $1 - \hat{y}$ is the predicted probability for class 0.

The intuition behind using matrix factorization to solve the recommendation problem is that there should be some latent features that determine how a user rates an item. These latent features can be used for representing users and items.

Definició 3.3 (Latent features). Característiques o variables subjacents o amagades dins d'un conjunt de dades que no s'observen directament però que es dedueixen de les dades disponibles.

If we can discover these latent features, we should be able to predict a rating with respect to a certain user and a certain item, because the features associated with the user should match (are similar) with the features associated with the item.

Siguin P una matriu $|U| \times K$ i Q una matriu $|D| \times K$, tal que $K \ll |U|$ i $K \ll |D|$ és el nombre de *latent features* i tal que $PQ^T = \hat{R} \approx R$.

- each row of P would represent the strength of the associations between a user and the features.
- each row of Q would represent the strength of the associations between an item and the features.

sparse observed ratings $\implies$ latent factor embeddings $\implies$ dense *predicted* ratings.

To get the prediction of a rating of an item d_j by u_i , we calculate the dot product of the two vectors corresponding to u_i and d_j :

$$\hat{r}_{ij} = p_i^T q_j = \sum_{k=1}^K p_{ik} q_{kj}. \quad (3.1)$$

Now, we have to find a way to obtain P and Q from a very large matrix R . Per exemple, podem omplir-les amb valors random, anem fent (3.1) i:

$$e_{ij}^2 = (r_{ij} - \hat{r}_{ij})^2 = \left(r_{ij} - \sum_{k=1}^K p_{ik} q_{kj} \right)^2.$$

Minimitzem aquest error amb el *gradient descend*:

$$\begin{aligned} \frac{\partial}{\partial p_{ik}} e_{ij}^2 &= -2(r_{ij} - \hat{r}_{ij})(q_{kj}) = -2e_{ij} q_{kj} \\ \frac{\partial}{\partial q_{ik}} e_{ij}^2 &= -2(r_{ij} - \hat{r}_{ij})(p_{kj}) = -2e_{ij} p_{kj} \end{aligned}$$

Definició 3.4 (Factorization Machines). A more general model framework that can extend the latent factor approach to incorporate arbitrary auxiliary features to represent users and items, and specialized loss functions that directly optimize item rank-order using implicit feedback data.

1. The base features will be binary vectors of user and item indicators.
2. FM models work with categorical data represented as binary integers. Auxiliary features must be represented by a one-hot encoding.
3. Let $x \in \mathbb{R}^d$ denote the feature vectors of one sample, and denote the corresponding label (binary or not):

$$\hat{y}(x) = w_o + \sum_{i=1}^d w_i x_i + \sum_{i=1}^d \sum_{j=i+1}^d W_{ij} x_i x_j$$

$w_o \in \mathbb{R}$ global bias, $w \in \mathbb{R}^d$ feature weights and $W \in \mathbb{R}^{d \times d}$ weights of the feature pair interactions.

It can capture feature interactions at least for two features at a time but we have now ended up with $O(d^2)$ parameters which means we now require a lot more time and memory.

Definició 3.5 (Factorized interaction parameters). To solve this problem, FMs instead use factorized interaction parameters:

$$\hat{y}(x) = w_o + \sum_{i=1}^d w_i x_i + \sum_{i=1}^d \sum_{j=i+1}^d (v_i^T v_j) x_i x_j.$$

This greatly decreases the number of parameters to estimate. No inference can be made about a preference for items that were both been seen by a user and is shown as a question mark.

Learn rank-order directly instead of minimizing prediction error by using loss functions that are based on the relative ordering of items instead of their raw scores.

Definició 3.6 (BPR). In BPR, instead of taking one item, item pairs will be considered as training data. Optimization would be performed based on the rank of these user-item pairs instead of scoring just on the user-item interaction. $D = \{(u, i, j)\}$, «user u is assumed to prefer item i over item j ».

$$\sum_{(u,i,j) \in D} -\ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}), \quad \sigma = \frac{1}{1 + e^{-x}},$$

and $\hat{y}_{ui}, \hat{y}_{uj}$ are the (FM) predicted scores of the user u to (seen) item i and (unseen) item j , respectively. This function has a minimum when, for every user u , seen items have a higher score than unseen items: $\hat{y}_{ui} - \hat{y}_{uj} > 0$.

3.7 (Content based vs. collaborative filtering). Content-based filtering makes recommendations based on user preferences for product features. Collaborative filtering, on the other hand, utilizes user-item interactions across a population of users in order to make recommendations for one particular user

The underlying assumption in both of these systems is that all of the historical interactions are equally important to the user's current preference, but in reality, this may not be true. For instance, recently viewed items may actually be more relevant than others.

Definició 3.8 (Session-based recommendation). These systems rely heavily on the user's most recent interactions, rather than on the user's historical preferences.

4

EL PROBLEMA DELS ÍTEMS FREQUENTS

Quins són els subconjunts d'ítems que apareixen de manera més freqüent a les bosses?

Definició 4.1 (Conjunt d'ítems més freqüents). Suposem que considerem el conjunt U d'ítems.

- Donat un subconjunt d'ítems $I \subset U$, definim el *suport* d' I com el nombre de bosses (o transaccions) que contenen el subconjunt I .
- Donat un valor predefinit s , anomenem *conjunt d'ítems freqüents* a cada un dels subconjunts d'ítems que tenen un suport igual o superior a s .

Exemple 4.2. Si els ítems són els productes d'un supermercat i les bosses són el que un client compra un dia determinat, una de les connexions interessants que podríem trobar és, per exemple, que molta gent compra cervesa i bolquers al mateix temps.

Exemple 4.3. Si els ítems són documents, les bosses són frases, i definim que un ítem/document està a una bossa/frase si la frase està al document, els conjunts d'ítems freqüents poden indicar problemes de plagiarisme.

Definició 4.4. $\{i_1, \dots, i_k\} \rightarrow j$ significa que si la bossa conté els ítems $i_1, \dots, i_k$, aleshores és molt probable que contingui j . La confiança d'aquesta regla d'associació és la probabilitat condicional de j donats $i_1, \dots, i_k$ (i.e. $C = p(j|i_1, \dots, i_k)$). L'interès es defineix com la diferència entre la seva confiança i la fracció de bosses que contenen j (i.e. $I = p(j|i_1, \dots, i_k) - p(j)$).

4.5. A tenir en compte:

- El problema és trobar totes les regles d'associació amb suport $\geq s$ i confiança $\geq c$. Hem de trobar tots els conjunts d'ítems amb suport alt i després totes les regles d'associació amb suport i interès suficients.
- Si $\{i_1, \dots, i_k\} \rightarrow j$ té suport i confiança elevats (per exemple, 1% i 50%, respectivament), llavors tant $\{i_1, \dots, i_k\}$ com $\{i_1, \dots, i_k, j\}$ seran freqüents.
- Per aquests algorismes, l'ús de la memòria principal és el recurs més crític. La probabilitat de que un conjunt d'ítems sigui freqüent baixa de forma exponencial respecte a la mida del conjunt.

Algoritme 4.6 (Trobar parelles freqüents). *Tres aproximacions al problema:*

1. *Naïf.* Llegim el fitxer un cop i posem a una matriu el nombre d'ocurrències de cada parella. Complexitat $O(k^2)$, on k és el nombre d'elements.
2. *Emmagatzemar només les tripletes $[i, j, c]$ tals que $\text{count}(i, j) = c$, amb $c > 0$, en forma de llista o diccionari.*
 - Si els enters i els identificadors dels ítems es poden guardar en 4 bytes, en una llista com a mínim necessitem 12 bytes per cada parella. Si ho guardem en un diccionari (amb $[i, j]$ com a clau) necessitem una mica més de memòria addicional.
 - En el pitjor dels casos, necessitem $\frac{12}{2}n^2$ bytes per guardar-les (la matriu és simètrica).
3. *Podem reduir espai si intentem emmagatzemar tots els $\binom{n}{2}$ comptadors de manera que sigui fàcil trobar-los a memòria donada la parella (i, j) sense haver de guardar (i, j) .*
 - 3.1. Numerem els ítems.
 - 3.2. Emmagatzemarem el comptador de $\{i, j\}$ en una matriu triangular $A[i, j]$. Amb això estalviem l'espai per guardar els identificadors dels productes i la meitat de la matriu.

3.3. De fet, si mantenim els comptadors de les parelles en ordre lexicogràfic podem guardar la matriu en una llista triangular:

$$A = [a_{(1,2)}, \dots, a_{(1,n)}, a_{(2,3)}, \dots, a_{(n-1,n)}] \implies \text{count}(i, j) = A \left[(i-1) \frac{n-i}{2} + j - i \right].$$

El nombre total de parelles és $\frac{n(n-1)}{2}$, que ocupen un total de $2n^2$ bytes.

Observació 4.7.

- El mètode de la matriu triangular (4 bytes per parella) és millor que un diccionari (12 bytes per parella) si al menys $\frac{1}{3}$ de les $\binom{n}{2}$ parelles apareix en alguna bossa. Si no, són millor els diccionaris.
- Els conjunts de $n > 2$ ítems no tenen tants problemes per ser emmagatzemats, normalment n'hi ha molts menys que parelles!

Algoritme 4.8 (Apriori). L'algorisme Apriori és un mètode que busca conjunts d'ítems freqüents amb molt poques lectures de les dades i fa un ús molt limitat de la memòria.

1. *Monotonia:* Si un conjunt d'ítems apareix al menys s vegades al conjunt, tots els seus possibles subconjunts també apareixen al menys s vegades!
2. Si un ítem i no apareix a s bosses, llavors cap conjunt que inclogui i pot aparèixer a s bosses.




Figura 1: Algorisme apriori

Per construir els conjunts de k ítems a partir dels de $k-1$, construïm dos k -conjunts (conjunts de mida k) a partir dels anteriors:

- C_k , els k -conjunts candidats. Aquells conjunts que poden ser freqüents, basant-se en la informació de la passada per $k-1$.
- L_k , el conjunt de k -conjunts realment freqüents.

El resultat final com a conjunt d'ítems freqüents és: $L_1 \cup L_2 \cup L_3 \cup \dots \cup L_n$, on n és el màxim nombre d'elements que pot tenir el conjunt per ser considerat freqüent (recordem que depenem del suport s).

Observació 4.9 (Regles d'associació). Generarem tots els subconjunts no buits de $I = L_n$. Per a cada subconjunt no buit s de I produïrem una regla $s \longrightarrow \{I - s\}$ si $\frac{\text{suport}(I)}{\text{suport}(s)} \geq \text{confiança mínima}$.

Val la pena revisar l'exemple.

HIPÒTESIS, INFERÈNCIES I A-B TESTING

5.1 (Per què la inferència). Les dades no sempre són concloents sobre una qüestió i diferents analistes poden obtenir diferents conclusions. La ciència de dades ha de seguir una metodologia que minimitzi els errors i les sobre-interpretacions a partir de les dades.

Definició 5.2 (Estadística freqüentista). L'estadística freqüentista parteix del fet de suposar que hi ha una població (infinita) de la que prenem una mostra (finita). La població està regida per una funció de distribució desconeguda, caracteritzada per uns paràmetres que s'aproximen amb la mostra però amb una incertesa inevitable.

Definició 5.3 (Validació). Segons el plantejament clàssic de l'estadística, la validació consisteix en avaluar la probabilitat del resultat obtingut (o més intens) sota la hipòtesis nul·la (o el que és el mateix, quina és la probabilitat que el resultat sigui fruit de la casualitat). Tres opcions:

1. Disposem d'un model teòric que ens diu quina és la funció de distribució de probabilitats de l'esdeveniment.
2. Diferència entre dues mitjanes.
3. No disposem d'un model teòric que ens permeti usar la funció de distribució mostral.

Definició 5.4 (Diferència entre mitjanes). La distribució de la diferència entre les mitjanes es pot considerar com la distribució que es produiria si repetim els següents tres passos una i altra vegada:

1. Mostreja valors de la població 1 i valors de la població 2.
2. Calcula les mitjanes de les dues mostres ($\hat{\mu}_1$ i $\hat{\mu}_2$).
3. Calcula la diferència entre les mitjanes ($\hat{\mu}_1 - \hat{\mu}_2$).

Es pot demostrar que la distribució mostral de la diferència entre les mitjanes de dues distribucions arbitràries segueix una distribució normal $N(\mu, \sigma^2)$, on:

- $\mu = \mu_1 - \mu_2$ és la mitjana de la primera distribució i μ_2 de la segona.
- $\sigma^2 = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$, on σ_1^2 és la desviació de la primera distribució i σ_2^2 de la segona.
- n_1 i n_2 són el nombre d'elements de la mostra de cada distribució.
- Sota la hipòtesi nul·la:

$$\begin{cases} \mu_1 = \mu_2 \implies \mu = 0 \\ \sigma_1^2 = \sigma_2^2 \implies \sigma^2 \approx \frac{\hat{\sigma}^2}{n_1} + \frac{\hat{\sigma}^2}{n_2}, \end{cases}$$

on $\hat{\sigma}^2$ és la desviació de les dades de les dues mostres agregades.

Si les etiquetes realment no importen (hipòtesi nul·la), llavors redistribuir-les entre les dades no ha de tenir cap efecte en la distribució mostral de la diferència entre mitjanes.

Definició 5.5 (Shuffling). Barrejar les etiquetes respecte a les mostres i recalculer les mitjanes i la seva diferència. Si això ho fem moltes vegades podem construir la distribució mostral de la diferència entre mitjanes,

comptar quantes vegades surt una diferència més gran que la observada i assignar aquesta probabilitat al valor observat.

Definició 5.6 (*Bootstrap*). El mètode de bootstrap ens permet crear una aproximació robusta de la distribució mostral d'aquests paràmetres (inclosa la mitjana) a partir d'aplicar un mostreig aleatori amb reemplaçament. Donat un conjunt d' N elements, el mostreig aleatori amb reemplaçament consisteix en:

1. Assignar un nombre enter a cada element.
2. Seleccionar N elements del conjunt (alguns d'ells possiblement repetits) mitjançant la generació de nombres aleatoris de l'interval d'enters $(1, \dots, N)$.

Conclusions

- L'estadística ens ajuda a quantificar l'incertesa d'un resultat, però el significat d'un resultat no depèn de les dades ni de la validació dels resultats, sinó de l'analista.
- Sempre cal ser escèptic i no fer proposicions massa agosarades sobre els resultats. L'única forma d'augmentar la certesa sobre algun efecte és repetir l'experiment moltes vegades.